



UNIVERSIDAD TÉCNICA DE AMBATO
FACULTAD DE INGENIERÍA EN SISTEMAS ELECTRÓNICA E INDUSTRIAL
Carrera de Software
Ciclo Académico: Agosto 2026 – Diciembre 2026



INFORME DE GUÍA PRÁCTICA

I. PORTADA

CAMPO	DETALLE INSTITUCIONAL
Tema:	Implementación y Evaluación de Sistemas de Recomendación Colaborativos, Demográficos, Basados en Contenido y Basados en Conocimiento/Utilidad sobre los Cuatro DataFrames del Banco Comercial (Financial_ijs)
Unidad de Org. Curricular:	PROFESIONAL
Nivel y Paralelo:	6to Software "A"
Alumnos participantes:	Cobos Taco Alison Marcela Laguna Flores Henry Daniel
Asignatura:	Inteligencia de Negocios
Docente:	Ing. Ruben Nogales, Mg.

II. INFORME DE GUÍA PRÁCTICA

2.1 Objetivos

General:

Diseñar, implementar y evaluar una arquitectura integral de sistemas de recomendación aplicando las técnicas de filtrado demográfico (K-Means), colaborativo (Slope One, Correlación de Pearson y Similitud de Coseno), basado en contenido (Item-to-Item con ponderación ITF) y basado en conocimiento/utilidad (reglas de scoring y límites de endeudamiento) sobre los cuatro DataFrames analíticos del caso `Financial_ijs`, garantizando recomendaciones personalizadas, viables financieramente y no triviales.

Específicos:

- **Justificar y asignar a cada uno de los cuatro DataFrames del proyecto el paradigma de recomendación correspondiente:** Vincular `df_cliente consolidado` al enfoque Demográfico, `df_transacciones` al Colaborativo, `df_ordenes` al Basado en Contenido y `df_prestamos` al Basado en Conocimiento y Utilidad.
- **Implementar experimentalmente los modelos matemáticos vistos en clase:** Evaluar los algoritmos Slope One ($f(x) = x + b$), Item-to-Item de Amazon (co-adquisición binaria), métricas de Coseno y Pearson, ponderación logarítmica de frecuencia inversa (ITF) y segmentación por clústeres.
- **Validar los resultados mediante inferencia real y evidencias visuales:** Demostrar la efectividad de los modelos mediante casos de estudio de clientes reales de la entidad bancaria, contrastando el rendimiento cualitativo de las técnicas y su integración en la arquitectura DW/BI.

2.2 Modalidad

Presencial.

2.3 Tiempo de duración

Presenciales: 6 horas | **No presenciales:** 0 horas.

2.4 Instrucciones

Seguir rigurosamente la plantilla oficial de la Guía APE de la Universidad Técnica de Ambato, presentando el informe en formato analítico y descriptivo fundamentado en evidencias gráficas, tablas de inferencia y formulación matemática, sin incluir código fuente en el cuerpo del documento.

2.5 Listado de equipos, materiales y recursos

- Computador personal con soporte para procesamiento vectorial y manipulación de datos en memoria.
- Entorno de programación científica Python 3.12 (NumPy, Pandas, SciPy, Matplotlib, Seaborn, Scikit-Learn).
- Conjuntos de datos limpios y auditados del banco `Financial_ijs` (`df_cliente consolidado_clean`, `df_transacciones_completado`, `df_ordenes_clean` y `df_prestamos`).
- Sistema de control de versiones Git y repositorio remoto en GitHub.

TAC (Tecnologías para el Aprendizaje y Conocimiento) empleados:

☒ Plataformas educativas ☐ Simuladores y laboratorios virtuales ☒ Aplicaciones educativas (VS Code, Jupyter) ☒ Inteligencia Artificial

2.6 Actividades por desarrollar

1. Justificación Metodológica: ¿Por qué se asignó cada sistema a cada DataFrame?

En el sector bancario, los datos residen en tablas con granularidades, volúmenes y dinámicas operativas completamente diferentes. Por este motivo, se realizó un mapeo metodológico estricto entre los cuatro DataFrames limpios del proyecto y las familias teóricas de recomendación expuestas en la cátedra (Montaner et al., 2003):

DATAFRAME	GRANULARIDAD	SISTEMA ASIGNADO	JUSTIFICACIÓN TÉCNICA Y DE NEGOCIO
df_cliente_consolidado	5,369 clientes × 30 cols	Sistema Demográfico (K-Means)	Al contener atributos sociodemográficos sin transacciones, es la única técnica capaz de solucionar el arranque en frío (Cold Start) para clientes nuevos.
df_transacciones	1,056,320 movs × 22 cols	Sistema Colaborativo (Slope One, Pearson, Coseno)	Requiere la masa crítica de interacciones acumuladas de toda la comunidad para descubrir correlaciones de consumo implícito entre productos.
df_ordenes	6,471 órdenes × 14 cols	Sistema Basado en Contenido (Item-to-Item + ITF)	Modela los atributos de los contratos fijos . El factor ITF penaliza pagos masivos cotidianos (SIPO) para favorecer productos de nicho de alto margen.
df_prestamos	682 créditos × 24 cols	Conocimiento y Utilidad (Diapositiva 4 PDF 2)	En crédito no se puede recomendar por "popularidad" . Requiere reglas de scoring de riesgo y una función de utilidad donde cuota ≤ 30% del salario neto .

2. Fundamentación de las Fórmulas Matemáticas Utilizadas

Todos los modelos implementados responden a las formulaciones matemáticas exactas impartidas en clase:

- **Algoritmo Slope One (Lemire et al., 2005):** Predicción lineal basada en desviaciones medias:

$$f(x) = x + b, \quad \text{donde} \quad b = \Sigma (r_{\{u, i\}} - r_{\{u, j\}}) / |S_{\{i, j\}}|$$

- **Similitud de Coseno (Diapositivas 11 y 16):** Proximidad angular continua y binaria:

$$\cos(\theta) = (A \cdot B) / (||A|| \cdot ||B||) = \Sigma (A_i B_i) / [\sqrt{\Sigma A_i^2} \sqrt{\Sigma B_i^2}]$$

- **Correlación de Pearson (Diapositiva 11):** Afinidad lineal centrada en la media:

$$r_{\{i, j\}} = \Sigma (r_{\{u, i\}} - \bar{r}_i)(r_{\{u, j\}} - \bar{r}_j) / [\sqrt{\Sigma (r_{\{u, i\}} - \bar{r}_i)^2} \sqrt{\Sigma (r_{\{u, j\}} - \bar{r}_j)^2}]$$

- **Frecuencia Inversa de Ítems (ITF):** Ponderación logarítmica de especificidad:

$$ITF(i) = \ln(N / |u \in U : \text{posee ítem } i|)$$

- **Distancia Euclídea para Clustering K-Means (PDF 1, Diapositiva 3):**

$$d_E(P_1, P_2) = \sqrt{\Sigma (x_{\{2, k\}} - x_{\{1, k\}})^2}$$

3. Arquitectura de Cómputo Empresarial: Desacoplamiento Offline, Nearline y Online (Diapositiva 9)

Inspirado en la arquitectura de referencia de **Netflix y Amazon Web Services (AWS)** expuesta en la Diapositiva 9 del PDF 2, los cuatro sistemas se distribuyen estratégicamente en tres capas temporales de cómputo:

```
=====
ARQUITECTURA DE PROCESAMIENTO DW/BI (BANCO COMERCIAL)
=====

[CAPA 1: OFFLINE / BATCH] (Horas - Procesamiento nocturno en Data Warehouse)
├─ df_cliente_consolidado_clean → Clustering K-Means (Centroides demográficos)
├─ df_transacciones_completado → Matrices masivas de Pearson (r) y Coseno (cos θ)
└─ df_ordenes_clean → Factores de Frecuencia Inversa ITF =  $\ln(N / n_i)$ 
                        |
                        ▼ (Tablas precalculadas y matrices base)
[CAPA 2: NEARLINE / STREAMING] (Segundos - Eventos asíncronos en colas de mensajes)
├─ Nuevo Retiro / Pago (Transacción) → Actualización incremental Slope One:  $f(x) = x + b$ 
└─ Nueva Domiciliación (Orden) → Actualización de vector binario Item-to-Item (0 -> 1)
                        |
                        ▼ (Caché en memoria Redis / EVCache)
[CAPA 3: ONLINE / TIEMPO REAL] (< 50 ms - Inferencia síncrona en Banca Móvil / Web)
├─ df_prestamos (Filtro de Riesgo) → Regla de exclusión morosa (Estatus B y D bloqueados)
├─ Salario disponible distrital → Restricción de Utilidad: Cuota mensual  $\leq 30\%$  Salario
├─ Cliente nuevo sin historial → Onboarding Demográfico: Distancia euclídea  $d_E$ 
└─ SERVING LAYER → Renderizado del Top-3 de productos recomendados
=====
```

A. Capa Offline (Batch): Procesa por lotes durante la madrugada el millón de transacciones, actualizando los centroides K-Means, matrices completas de Pearson y Coseno, y pesos ITF.

B. Capa Nearline (Streaming): Reacciona en segundos (\$1\$ a \$5\$ s) ante eventos transaccionales. El algoritmo Slope One suma $+1$ al conteo y actualiza la media $b_{(i,j)}$ en tiempo $O(1)$ en caché Redis.

C. Capa Online (Tiempo Real < 50 ms): En el instante en que el cliente abre la banca móvil, aplica las reglas de scoring crediticio de `df_prestamos`, restringe la cuota al 30% del salario y entrega el Top-3 en pantalla.

2.7 Resultados obtenidos (CERO CÓDIGO)

2.7.1 Sistema de Recomendación Demográfico: df_cliente_consolidado_clean.csv

Este sistema se fundamenta en la segmentación sociodemográfica para emparejar **estereotipos con catálogos de productos** (Montaner et al., 2003), resolviendo el arranque en frío cuando el cliente carece de movimientos bancarios.




Figura 1. Segmentación sociodemográfica de los 5,369 clientes mediante K-Means (Lloyd) sobre edad y salario distrital, mostrando centroides y arquetipos de negocio.

Análisis Descriptivo y de Negocio (Figura 1):

La Figura 1 muestra la agrupación de los 5,369 clientes en cuatro clústeres bien diferenciados:

- **Clúster 1 (Adultos Ahorradores - Azul, n=1,420):** Clientes entre 42 y 65 años con salarios medios (8,800 - 9,800 CZK) y saldos pasivos elevados. Demandan productos de rentabilidad garantizada y protección patrimonial (SEGURO, SERVICIOS_HOGAR).
- **Clúster 2 (Jóvenes Urbanos - Naranja, n=1,185):** Segmento joven (18 a 35 años) concentrado en Praga y zonas metropolitanas con salarios superiores a 11,500 CZK. Presentan alta bancarización digital y son candidatos predilectos para TARJETA y LEASING.
- **Clúster 3 (Perfil Estándar - Verde, n=1,680):** Masa laboral activa con ingresos medios y transaccionalidad equilibrada. Núcleo natural para domiciliación de consumos domésticos (SIPO).
- **Clúster 4 (Adultos Mayores Rurales - Rojo, n=1,084):** Clientes de edad avanzada en distritos rurales periféricos.

Ejemplo Real de Aplicación: El cliente #5080 (23 años, recién registrado en Praga con salario de 12,541 CZK, sin transacciones) es asignado al Clúster 2 por distancia euclídea ($d_E = 0.41\$$). La banca móvil le recomienda de inmediato la **Tarjeta de Débito Internacional sin comisión** y la **Línea de Crédito Joven**.

2.7.2 Sistema de Recomendación Colaborativo: df_transacciones_completado.csv.gz

A. Técnica 1: Algoritmo Slope One (Lemire et al., 2005)




Figura 2. Matriz de desviaciones medias $b_{i,j}$ entre productos financieros y tabla de inferencia predictiva para clientes muestra bajo el algoritmo Slope One.

Análisis Descriptivo y de Negocio (Figura 2):

La matriz simétrica de diferencias $b_{i,j}$ revela que PRESTAMO registra una desviación positiva sistemática respecto a SERVICIOS_HOGAR (+0.42) y TARJETA (+0.35), reflejando que los clientes con préstamos mantienen una intensidad transaccional superior al promedio. Por su parte, la diferencia entre LEASING y SEGURO es de apenas -0.04, demostrando paridad casi perfecta entre ambos productos de cobertura y financiamiento vehicular.

Ejemplo Real: Para el **Cliente #2** (con PRESTAMO = 4.20 y SERVICIOS_HOGAR = 3.50), el modelo proyecta que su mayor afinidad insatisfecha corresponde a SEGURO con un score esperado de **3.82 sobre 5.0**, recomendándole contratar la póliza.

B. Técnica 2: Correlación de Pearson (Diapositiva 11)




Figura 3. Matriz de Correlación de Pearson entre productos financieros en escala de -1.0 a +1.0.

Análisis Descriptivo y de Negocio (Figura 3):

El mapa de calor aísla las tendencias lineales de contratación conjunta:

- **Fuerte correlación positiva entre PRESTAMO y LEASING ($r = +0.638$):** Existe alta complementariedad comercial; quienes buscan créditos personales tienen propensión natural a contratar leasing de bienes de capital.
- **Correlación positiva entre SEGURO y SERVICIOS_HOGAR ($r = +0.512$):** Quienes domicilian luz y agua (SIPO) tienden a domiciliar pólizas familiares (POJISTNE), justificando campañas de empaquetamiento (*bundling*).
- **Correlación neutra entre TARJETA y LEASING ($r = -0.042$):** Indica independencia operativa, evitando campañas de venta cruzada ineficaces entre ambos.

C. Técnica 3: Similitud de Coseno (Diapositiva 11)




Figura 4. Matriz de Similitud de Coseno continua entre vectores de uso de productos financieros (valores de 0.0 a 1.0).

Análisis Descriptivo y de Negocio (Figura 4):

La Figura 4 evalúa el ángulo vectorial en el espacio de clientes. **SERVICIOS_HOGAR** exhibe la mayor proximidad angular global frente a todos los demás productos (coseno de 0.78 a 0.86) debido a su carácter de servicio base transversal en más del 64% de los clientes. Asimismo, **PRESTAMO** y **SEGURO** registran una similitud de 0.714, confirmando que comparten un solapamiento muy estrecho en los hábitos de consumo bancarizados.

2.7.3 Sistema de Recomendación Basado en Contenido: df_ordenes_clean.csv

Modela los contratos permanentes aplicando el algoritmo **Item-to-Item de Amazon (Linden et al., 2003)** sobre una matriz binaria (0/1), complementado con la **Ponderación por Frecuencia Inversa de Ítems (ITF)**.




Figura 5. (A) Matriz de Similitud Coseno Binario estilo Amazon y (B) Comparativa de Popularidad frente al Factor de Ponderación por Frecuencia Inversa (ITF).

Análisis Descriptivo y de Negocio (Figura 5):

El Panel A demuestra que la similitud binaria entre **SERVICIOS_HOGAR** y **TRANSF_EXTERNA** es de 0.54. El Panel B resuelve el dilema de la popularidad: **SERVICIOS_HOGAR** es contratado por 3,439 clientes, lo que hunde su peso ITF a un mínimo de 0.45. Por el contrario, productos estratégicos como **LEASING** (341 clientes, ITF = 2.76) y **SEGURO** (533 clientes, ITF = 2.31) multiplican su peso hasta por 6 veces. Gracias a la fórmula ITF, el recomendador prioriza contratos de alto margen en lugar de recomendar siempre servicios comunes.

Ejemplo Real: El Cliente #19 posee una orden de **SERVICIOS_HOGAR**. La ponderación ITF eleva a **SEGURO** (Score ponderado: 1.15) y **LEASING** (Score: 1.05), recomendándole con éxito la póliza de protección para su vivienda.

2.7.4 Sistema Basado en Conocimiento y Utilidad: df_prestamos.csv

Conforme a la Diapositiva 4 del PDF 2, los créditos de alto riesgo no pueden recomendarse por mera afinidad estadística; requieren reglas lógicas de conocimiento explícito y una función de utilidad financiera prudencial.




Figura 7. (A) Regla de Conocimiento: Matriz de Elegibilidad Crediticia basada en estados de cartera y (B) Función de Utilidad Financiera: Simulación de Cuota vs. Salario según el plazo.

Análisis Descriptivo y de Negocio (Figura 7):
Sobre los 682 créditos auditados en df_prestamos.csv:

- Panel A (Elegibilidad por Regla de Conocimiento): Los contratos concluidos con pago puntual (Estatus A: 203 préstamos, 29.8%) tienen pre-aprobación inmediata. Los activos al corriente (Estatus C: 403 préstamos, 59.1%) son elegibles bajo refinanciamiento. En cambio, clientes con impago (Estatus B: 31 préstamos) o morosidad activa (Estatus D: 45 préstamos) son bloqueados automáticamente por la regla de exclusión de riesgo.
- Panel B (Función de Utilidad Financiera): Impone la restricción de que la cuota sugerida no exceda el 30% del salario neto distrital (3,000 CZK para un salario de 10,000 CZK). Un crédito de 100,000 CZK a 12 meses (cuota: 8,698 CZK) violaría la utilidad; el motor optimiza el plazo y recomienda el crédito a 48 meses (cuota: 2,441 CZK) o 60 meses (cuota: 2,027 CZK), ubicando al cliente en la Zona de Utilidad Aceptable.

Ejemplo Real: El Cliente #45 solicita un crédito de 80,000 CZK. El sistema verifica que no tiene historial moroso (es apto) y consulta su salario distrital (9,450 CZK, límite 30% = 2,835 CZK). Le recomienda un Préstamo Personal a 36 meses con cuota fija de 2,506.80 CZK, garantizando un ratio seguro del 26.5%.

2.7.5 Cuadro Comparativo de Inferencia Real e Integración Híbrida

La Figura 6 consolida la inferencia cruzada simultánea de los modelos evaluados sobre clientes muestra reales del banco:

Cuadro Comparativo de Inferencia Real: Evaluación Cruzada de los Sistemas de Recomendación (Demográfico, Colaborativo con Slope One / Pearson / Coseno, y Contenido con ITF)						
Cliente	Productos Poseídos	Demográfico (K-Means)	Slope One (Lamire)	Correlación (Pearson)	Similitud (Coseno)	Contenido (Amazon + ITF)
Cliente #2 (Edad 53)	PRESTAMO, SERVICIOS_HOGAR	PRESTAMO, LEASING	SEGURO, TRANSF_EXTERNA	SEGURO, TARJETA	TARJETA, SEGURO	SEGURO, TRANSF_EXTERNA
Cliente #19 (Edad 56)	SERVICIOS_HOGAR, TARJETA	SERVICIOS_HOGAR, SEGURO	PRESTAMO, SEGURO	PRESTAMO, SEGURO	PRESTAMO, SEGURO	SEGURO, TRANSF_EXTERNA
Cliente #45 (Edad 46)	PRESTAMO, SEGURO	PRESTAMO, LEASING	TARJETA, LEASING	TARJETA, LEASING	LEASING, TARJETA	TARJETA, LEASING
Cliente #102 (Edad 40)	SERVICIOS_HOGAR, TRANSF_EXTERNA	PRESTAMO, LEASING	PRESTAMO, SEGURO	SEGURO, PRESTAMO	SEGURO, PRESTAMO	SEGURO, PRESTAMO

Figura 6. Cuadro comparativo de inferencia real: sugerencias generadas para clientes muestra bajo los enfoques Demográfico, Slope One, Pearson, Coseno y Contenido con ITF.

Cuadro Comparativo Técnico de las Técnicas Evaluadas

CRITERIO	DEMOGRÁFICO (K-MEANS)	SLOPE ONE (LEMIRE)	CORRELACIÓN PEARSON	SIMILITUD COSENO	CONTENIDO (AMAZON+ITF)	CONOCIMIENTO Y UTILIDAD
DataFrame	df_cliente_consolidado	df_transacciones	df_transacciones	df_transacciones	df_ordenes	df_prestamos
Tipo de Datos	Sociodemográficos	Calificaciones (1-5)	Calificaciones (1-5)	Vectores continuos	Matriz binaria (0/1)	Solvencia y estados de pago
Complejidad	$O(k)$ [Tiempo real]	$O(R_u \times I)$ [Lineal]	$O(I ^2)$ [Media]	$O(I ^2)$ [Media]	$O(1)$ [Lookup precalculado]	$O(1)$ [Reglas lógicas]
Cold Start	Excelente (Nativa)	Nula para nuevos	Nula para nuevos	Baja para nuevos	Media para nicho	Alta (Reglas condicionales)
Sesgo Popular	Alta (Moda clúster)	Media	Baja (Normaliza)	Alta (Favorece masivos)	Baja (Corregida con ITF)	Nula (Basada en riesgo)
Rol Híbrido	Onboarding nuevos	Motor transaccional	Bundling comercial	Proximidad de consumo	Venta cruzada sin comodines	Filtro de riesgo y límites

2.8 Habilidades blandas empleadas en la práctica

[] Liderazgo [] Trabajo en equipo [] Comunicación asertiva [x] Pensamiento crítico [] Adaptabilidad [x] Responsabilidad

2.9 Conclusiones

- **Justificación plena del enfoque híbrido multimodelo:** La investigación evidenció que ningún algoritmo individual resuelve satisfactoriamente todas las casuísticas del negocio bancario. Mientras el Sistema Demográfico (df_cliente_consolidado) es imprescindible para resolver el arranque en frío de clientes nuevos, el Sistema Colaborativo (df_transacciones) provee máxima precisión matemática para clientes activos, el Sistema de Contenido (df_ordenes) afina la especificidad mediante ITF, y el Sistema Basado en Conocimiento (df_prestamos) actúa como un cortafuegos ético y financiero indispensable que previene la sobreexposición crediticia.
- **Superioridad operativa de Slope One en producción transaccional:** En concordancia con los hallazgos de Lemire et al. (2005), Slope One demostró ser la alternativa de menor fricción computacional. Al sustentarse en desviaciones medias acumulativas ($f(x) = x + b$), permite actualizaciones incrementales en tiempo $O(1)$ cada vez que un cliente realiza un nuevo movimiento bancario, superando la pesada carga de recalcular matrices trigonométricas de Coseno o Pearson.
- **Control del sesgo de popularidad mediante ITF:** La introducción de la Frecuencia Inversa de Ítems (ITF) dentro del esquema Item-to-Item de Amazon corrigió de forma contundente la distorsión producida por productos de uso ubicuo como SERVICIOS_HOGAR (presente en 3,439 clientes, $\text{ext}\{ITF\} = 0.45$). Gracias a esta métrica, el motor bancario enfoca sus recomendaciones comerciales en productos de alta rentabilidad como LEASING ($\text{ext}\{ITF\} = 2.76$) y SEGURO ($\text{ext}\{ITF\} = 2.31$).

2.10 Recomendaciones

- **Implementar un Pipeline Híbrido Cascada en el Data Warehouse:** Configurar el motor de recomendaciones en el Data Mart corporativo de forma secuencial: aplicar el filtro Demográfico durante los primeros 30 días de antigüedad del cliente, transicionar hacia el modelo Colaborativo (Slope One + Coseno) una vez alcanzadas 5 transacciones registradas, y condicionar cualquier oferta de crédito al motor de Conocimiento y Utilidad de cartera.
- **Desacoplamiento temporal bajo Arquitectura Lambda:** Programar la recomputación masiva de matrices de Coseno, Pearson y centroides K-Means en la capa Offline (Batch) durante mantenimientos nocturnos, almacenando los rankings Top- K en cachés de memoria (como Redis o tablas indexadas en SQL Server) para habilitar consultas Online en la banca móvil con tiempos de respuesta inferiores a 50 milisegundos.
- **Auditoría periódica de la función de utilidad crediticia:** Ajustar trimestralmente el umbral de endeudamiento del 30% y los plazos sugeridos en el sistema de conocimiento frente a fluctuaciones en la inflación y en la tasa de política monetaria fijada por el banco central.

2.11 Referencias bibliográficas (Norma IEEE)

1. J. Montaner, B. López, and J. L. de la Rosa, "A taxonomy of recommender agents on the Internet," *Artificial Intelligence Review*, vol. 19, no. 4, pp. 285–330, Jun. 2003.
2. D. Lemire and A. Maclachlan, "Slope One predictors for online rating-based collaborative filtering," in *Proc. SIAM Int. Conf. Data Mining (SDM)*, Newport Beach, CA, USA, 2005, pp. 471–475.
3. G. Linden, B. Smith, and J. York, "Amazon.com recommendations: Item-to-item collaborative filtering," *IEEE Internet Computing*, vol. 7, no. 1, pp. 76–80, Jan. 2003.
4. X. Amatriain and J. Basilico, "Netflix recommendations: Beyond the 5 stars (Part 1 and 2)," *Netflix Technology Blog*, Apr. 2012. [Online]. Available: <https://netflixtechblog.com/>
5. R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Indianapolis, IN, USA: Wiley, 2013.

2.12 Anexos

Anexo 1: Matriz de Conteo de Clientes Concurrentes entre Productos Financieros

Soporte muestral de usuarios con interacción simultánea que fundamenta las desviaciones de Slope One y correlaciones de Pearson:

PRODUCTO	PRESTAMO	SEGURO	SERVICIOS_HOGAR	LEASING	TARJETA	TRANSF_EXTERNA
PRESTAMO	682	84	446	58	114	162
SEGURO	84	533	362	41	89	128
SERVICIOS_HOGAR	446	362	3,439	231	548	812
LEASING	58	41	231	341	62	91
TARJETA	114	89	548	62	807	204
TRANSF_EXTERNA	162	128	812	91	204	1,197

Anexo 2: Repositorio Oficial del Proyecto en GitHub

Todos los scripts de cálculo matricial, pipelines ETL, modelos de datos y figuras de evidencia visual se encuentran alojados en:

<https://github.com/Hlagua/DocumentosBi>